

MEMORIA DEL PROYECTO

Modelo de transformación e integración de datos geoespaciales

aplicados a la energía hidráulica y solar en España

Carlos del Valle

Enero 2025

Índice

1. Introducción	3
1.1 El contexto de la información geoespacial en España	3
2. Objetivos del trabajo	3
3. Datos y fuentes empleados	3
3.1 Ámbito de hidrología.....	3
3.1.1 Infraestructura de embalses	3
3.1.2 Red fluvial y caudales.....	4
3.2 Ámbito fotovoltaico	5
3.2.1 Datos de ámbito meteorológico (histórico)	5
3.2.2 Obtención de datos fotovoltaicos: fuentes y APIs	6
3.2.3 Procesamiento ETL y algoritmo de eficiencia (Python).....	7
4. Metodología	7
4.1 Arquitectura de los sistemas de integración	7
4.1.1 Diseño del flujo de datos (Data Pipeline).....	7
4.2 Clasificación de librerías especializadas	8
4.2.1 Adquisición de datos y conectividad web	8
4.2.2 Procesamiento y normalización alfanumérica	8
4.2.3 Gestión y geoprocetamiento espacial	9
4.2.4 Persistencia y gestión de bases de datos	9
4.2.5 Utilidades de sistema y formatos de intercambio	9
4.3 Selección y justificación del sistema	9
4.3.1 Python: automatización y extracción de datos.....	9
4.3.2 PDI: normalización de flujos	9
4.3.3 FME: geoprocetamiento y geocodificación avanzada	9
4.3.4 PostGIS: repositorio de los datos geoespaciales.....	10
5. Implementación de los modelos de procesamiento y automatización	10
5.1 Normalización y filtrado de datos mediante PDI (Pentaho).....	10
5.1.1 Tratamiento de los datos fluviales.....	10
5.1.2 Tratamiento de los datos meteorológicos (histórico).....	11
5.1.3 Tratamiento de los datos meteorológicos (actualizado con localización)	13
5.1.4 Tratamiento de los datos de energía solar térmica	14
5.2 Procesamiento integral de datos espaciales en FME.....	15
5.2.1 Geocodificación y automatización del posicionamiento espacial aproximado	15
5.2.2 Obtención de imágenes satelitales y procesamiento geométrico de embalses	16
5.2.3 Análisis de datos ráster y cálculo energético	17
6. Fuentes de datos y APIs	18

1. Introducción

1.1 El contexto de la información geoespacial en España

En España, la información geoespacial es accesible para todo el público gracias a una sólida infraestructura de datos abiertos. Hoy en día, el verdadero desafío no está en la disponibilidad de los datos, sino en la complejidad de su transformación e integración para la obtención de resultados analíticos.

En el ámbito de la hidrología, esta dificultad es especialmente patente porque la información no está centralizada. En lugar de un sistema unificado, los datos están repartidos entre las distintas demarcaciones hidrográficas, que no comparten estructuras ni formatos normalizados, lo que impide la interoperabilidad entre organismos.

Paralelamente, el sector de la energía fotovoltaica se enfrenta a un escenario similar, en el que la gestión aislada de la información por parte de cada nivel administrativo dificulta una visión de conjunto. Esta separación no solo complica el análisis técnico, sino que puede generar conflictos institucionales por falta de entendimiento entre las partes.

2. Objetivos del trabajo

El objetivo principal es desarrollar un modelo de integración y transformación de datos hidrológicos y fotovoltaicos españoles que facilite su análisis temporal y espacial. El reto consiste en integrar todas las cuencas hidrográficas de España con sus respectivos embalses y ríos, de modo que sea posible conocer la energía hidráulica máxima y la generada en tiempo real.

Por otro lado, se obtendrá la información relativa a la energía fotovoltaica —temperatura, presión y otros factores que influyen en su generación— así como su precio.

3. Datos y fuentes empleados

3.1 Ámbito de hidrología

La recopilación de datos hidrológicos se ha estructurado en dos ejes principales, atendiendo a la naturaleza de la información y a su disponibilidad en la red: la infraestructura de embalses y la red fluvial (caudales).

3.1.1 Infraestructura de embalses

La información relativa al estado, la capacidad y la variación de los embalses se ha obtenido del portal embalses.net. Los datos se presentan en formato HTML y están separados por demarcaciones, por lo que el proceso ha requerido descargar y tratar individualmente cada una de las páginas de cuenca (16 en embalses.net), que posteriormente se agrupan en las nueve demarcaciones SAIH. La Tabla 1 muestra la estructura de una fila tipo y la Figura 1 la interfaz del portal.

Tabla 1. Estructura de los datos de embalses.net (fila de ejemplo).

Pantano	Capacidad (hm ³)	Embalsada (hm ³)	Variación (hm ³)
Alfilorios	8	4	0




Figura 1. Tabla de embalses de la cuenca Cantábrico en embalses.net. Todas las cuencas presentan el mismo formato.

3.1.2 Red fluvial y caudales

Los datos relativos a los ríos proceden del Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO). La información se gestiona a través de los Sistemas Automáticos de Información Hidrológica (SAIH), que controlan las cuencas hidrográficas de manera individualizada. Esta estructura administrativa implica que los datos de caudales y niveles también estén separados por demarcaciones. Todas las cuencas pueden consultarse en la página de [Sistemas SAIH del MITECO](#).

Las confederaciones hidrográficas publican sus datos en tres formatos distintos:

- **HTML estático:** Júcar, Segura, Guadalquivir y Duero.
- **JSON:** Ebro, Tajo y Guadiana.
- **HTML dinámico:** Miño-Sil y Cantábrico.

El detalle del método de descarga de cada cuenca se documenta en el archivo `FORMATO_DESCARGA_SAIH.md` del repositorio. Las Tablas 2 a 10 muestran, para cada cuenca, un ejemplo de los datos publicados.

Tabla 2. Resumen de caudales en puntos clave de la cuenca (SAIH Guadalquivir).

Punto de control	Cuenca/Río	Instantáneo (m³/s)	Media diaria (m³/s)
H04 Pedro Marín	Guadalquivir	5,02	4,82

Tabla 3. Resumen de caudales en puntos clave de la cuenca (SAIH Júcar).

Punto	Variable	Último valor (m³/s)	Umbral amarillo (m³/s)	Umbral naranja (m³/s)	Umbral rojo (m³/s)	Fecha último valor
<i>Cenia – Maestrazgo</i>						
EA 99 Salida Ulldecona	Caudal Río Cenia	0,82	20	75	150	13:20

Tabla 4. Resumen de caudales en puntos clave de la cuenca (SAIH Ebro).

Estación	Nivel (m)	Caudal (m³/s)	Tendencia
EBRO-CASTEJÓN	2,90	247,00	Abajo

Tabla 5. Resumen de caudales en puntos clave de la cuenca (SAIH Segura).

Descripción	Fecha	Valor
Temperatura (Canal Alto Taibilla)	12-01-2026 13:35	13,1 °C
Nivel Aforador Cabecera Canal Alto Taibilla	12-01-2026 13:35	0,32 m
Pluviómetro (Canal Alto Taibilla)	12-01-2026 13:35	0,0 mm
Caudal Cabecera Canal Alto Taibilla	12-01-2026 13:35	0,719 m³/s

Tabla 6. Resumen de caudales en puntos clave de la cuenca (SAIH Tajo).

Estación	Código	Provincia	Zona	Último caudal (m³/s)
C PPAL M.DCHA. ALAGÓN	19MD	Cáceres	ALAGÓN	0,000

Tabla 7. Resumen de caudales en puntos clave de la cuenca (SAIH Guadiana).

Tipo	Zona	Id.	Estación	Nombre	Nivel	Vol.	Vol.	Sup.	Pacum	Ih	Fecha y hora UTC
E	Z12	PYA	E1-01	Peñarroya	725,35	17,92	35,61	243,93	0	0	2026-01-12 12:30:00

Tabla 8. Resumen de caudales en puntos clave de la cuenca (SAIH Duero).

Variable	Valor	Fecha	Tendencia	Histórico
Dirección del viento	255,7 °	12/01/2026 13:30	url	url
Evaporación	n/d	12/01/2026 13:30	url	url
Humedad relativa del ambiente	82 %	12/01/2026 13:30	url	url
Nivel	1.043,01 m.s.n.m	12/01/2026 13:30	url	url
...	...	...	...	...
Caudal vertido	0,5 m³/s	12/01/2026 13:30	url	url

Tabla 9. Resumen de caudales en puntos clave de la cuenca (SAIH Miño-Sil).

Código estación	Nombre estación	Río	Tendencia	Estado de comunicaciones	Ver ficha
A004	RIO MIÑO EN CELA	MIÑO	→	Normal	url
Descripción	Fecha/Hora	Valor	Unidad	Estado alarma	Ver gráfico
Nivel río Miño en Cela Brazo Izquierdo	12/01/2026 13:00	15,13	m³/s	NORMAL	url

Tabla 10. Resumen de caudales en puntos clave de la cuenca (SAIH Cantábrico).

Código	Sistema	Municipio	Río	Nombre	Nivel	Caudal
1424	Eo	Ribera de Piquín	Eo	Ribera de Piquín	0,59	12,39

3.2 Ámbito fotovoltaico

3.2.1 Datos de ámbito meteorológico (histórico)

Para complementar la información hidrológica con variables climáticas en tiempo real (precipitaciones, rachas de viento y dirección), se han integrado los datos de la [Agencia Estatal de Meteorología \(AEMET\)](#). La fuente consiste en archivos CSV independientes para cada una de las 16 comunidades autónomas peninsulares.

El tratamiento de estos datos presentó dificultades por la falta de homogeneidad en los archivos de origen, que contenían «suciedad» estructural, errores en los encabezados y caracteres ocultos que impedían su lectura directa.

Los archivos descargados comparten una estructura similar, con las columnas que se indican a continuación, pero están mal formados por errores en el propio CSV. Estos errores se corrigieron con scripts en Python que permitieron su lectura correcta en Pentaho:

```
Estación, Provincia, Temperatura (°C), Velocidad del viento (km/h), Dirección del viento,
Racha (km/h), Dirección de racha, Precipitación (mm), Presión (hPa), Tendencia (hPa),
Humedad (%)
```

Las Tablas 11 y 12 muestran algunos ejemplos de estos archivos.

Tabla 11. Datos meteorológicos de AEMET: Andalucía (extracto).

Estación	Provincia	Temperatura (°C)	Velocidad del viento (km/h)	Dirección del viento	Racha (km/h)	Dirección de racha	Precipitación (mm)	Presión (hPa)	Tendencia (hPa)	Humedad (%)
Abla	Almería	10.6	0	Calma	8	Nordeste	0.0	909.6	-0.8	62.0
Adra	Almería	17.1	9	Norte	20	Norte	0.0	1008.0	-1,7	66.0
Aguilar de la Frontera	Córdoba	12.1	2	Este	13	Sudeste	0.0			82.0

Tabla 12. Datos meteorológicos de AEMET: Cantabria (extracto).

Estación	Provincia	Temperatura (°C)	Velocidad del viento (km/h)	Dirección del viento	Racha (km/h)	Dirección de racha	Precipitación (mm)	Presión (hPa)	Tendencia (hPa)	Humedad (%)
Alto Campoo	Cantabria	3.9	14	Noroeste	64	Noroeste	0.7	824.7	-0.4	89.0
Barcena de Cicero, Treto	Cantabria									
Castro Urdiales	Cantabria	10.5	12	Este	30	Este	0.0			88.0

3.2.2 Obtención de datos fotovoltaicos: fuentes y APIs

Más allá de la ubicación de las plantas solares, el interés estratégico del proyecto reside en entender cómo afecta el clima a la economía real. Para ello se ha diseñado un **Monitor de Rentabilidad Térmica**, una herramienta de inteligencia de negocio que mide no solo cuánta energía se produce, sino también cuánto dinero se «pierde» por el exceso de calor en las provincias españolas.

La toma de datos se realiza en tiempo real mediante la conexión con dos interfaces de programación de aplicaciones (APIs) oficiales, gestionadas con credenciales de acceso (tokens):

- **Red Eléctrica (ESIOS):** proporciona el precio de la luz hora a hora y la generación fotovoltaica nacional a través de su [API](#). Solo se emplean los indicadores necesarios para el trabajo: el indicador 1001 (precio PVPC), que da el precio de la luz en €/MWh en tiempo real, y el indicador 1739 (generación real fotovoltaica). Se eligieron por ser los más fiables y públicos de la API, ya que los indicadores inicialmente previstos (como el 10035 o el 1744) tenían más restricciones y un acceso más complejo.
- **AEMET:** proporciona la temperatura en las capitales de provincia a través de su [API OpenData](#). Se dejaron de usar valores aleatorios y se conectó el script con el archivo JSON descargado de la API (2026011112_IUSD02_LEMM.json), del que se lee la clave airTemperature. El dato se extrae en kelvin, por lo que el código le resta 273,15 para convertirlo a grados Celsius y poder calcular la pérdida de eficiencia, que se configura a partir de los 25 °C.

Con la combinación de precio (indicador 1001), generación (indicador 1739) y temperatura real, el sistema calcula finalmente la columna dinero_perdido_eur.

3.2.3 Procesamiento ETL y algoritmo de eficiencia (Python)

El núcleo del procesamiento reside en un script de Python (`etl_main.py`) que ejecuta la extracción, la transformación y el cálculo de pérdidas. La lógica de negocio sigue este flujo algorítmico:

1. **Desagregación espacial:** a partir del dato de generación nacional extraído de ESIOS, el script estima la producción local aplicando los coeficientes de potencia instalada por provincia.
2. **Cálculo físico (pérdida térmica):** se cruza la producción estimada con la temperatura real de la zona. Las placas solares pierden eficiencia cuando se calientan; el algoritmo detecta cuándo se superan los 25 °C y calcula automáticamente una penalización del 0,4 % por cada grado adicional.
3. **Cálculo económico:** la energía «evaporada» (MW no generados por calor) se multiplica por el precio actual de la luz (€/MWh), obteniendo el impacto económico directo de la climatología en la red.

4. Metodología

4.1 Arquitectura de los sistemas de integración

4.1.1 Diseño del flujo de datos (Data Pipeline)

La arquitectura del proyecto se basa en un enfoque híbrido que combina la flexibilidad de un lenguaje de programación con herramientas especializadas de extracción, transformación y carga (ETL). El uso conjunto de Python, FME y Pentaho Data Integration (PDI) permite gestionar la heterogeneidad de las fuentes (portales SAIH, APIs y *web scraping*), asegurando la integridad de la información y su correcta estructura en la base de datos PostGIS.

En el ámbito de la hidrología, la integración se realiza mediante un flujo diseñado para centralizar información heterogénea de manera eficiente. El flujo se inicia con la extracción de datos desde fuentes externas mediante técnicas de *web scraping*, con scripts especializados para cada dominio: `scraping.py` para la infraestructura de embalses y `descarga_saih.py` para la red fluvial.

Tras la captura, los resultados se almacenan temporalmente en formato CSV o JSON, según la estructura de la fuente. La fase de carga y transformación se diferencia según la naturaleza del dato: la información de embalses se integra directamente en la base de datos mediante el script de Python, mientras que los datos de los ríos se filtran y normalizan en PDI. Esta etapa es fundamental para garantizar que toda la información esté unificada y estandarizada antes de utilizarla en cualquier cálculo o análisis.

En el ámbito de la energía fotovoltaica se ha diseñado un flujo de trabajo híbrido dividido en tres fases:

1. **Extracción y limpieza con Python.** Se han desarrollado scripts específicos con la librería Pandas para la descarga y el preprocesamiento de los archivos. Esta fase fue crítica para:
 - Eliminar encabezados sobrantes y corregir el orden de las columnas.
 - Depurar caracteres de texto invisible y formatear correctamente los tipos de datos.
 - **Gestión de valores nulos:** solo se eliminan las filas cuyos campos son todos nulos (100 %). Si una fila contiene al menos un dato real, se conserva para mantener la integridad de la serie temporal.
2. **Normalización en Pentaho Data Integration.** Una vez depurados los CSV, se procedió a su unificación en Pentaho. Como los datos estaban fragmentados por regiones, se aplicaron las siguientes transformaciones:

- **Añadir constantes:** se agregó una columna identificativa en cada flujo para etiquetar la comunidad autónoma de origen, lo que permite la trazabilidad del dato en la tabla final (Tabla 13).

Tabla 13. Resultado de la transformación «Añadir constantes» (extracto).

Tendencia (hPa)	Humedad (%)	comunidad	fecha_importacion
-0.8	62.0	Andalucía	2026-01-08 22:12:39.782055
-1,7	66.0	Andalucía	2026-01-08 22:12:39.782055
	82.0	Andalucía	2026-01-08 22:12:39.782055

- **Selecciona/Renombra valores:** se estandarizaron los nombres de los campos (por ejemplo, temperatura o direccion_del_viento) para que las columnas de las 16 fuentes tengan la misma nomenclatura y abreviaturas (Tabla 14).

Tabla 14. Resultado de la transformación «Selecciona/Renombra valores» (extracto).

tendencia	humedad	comunidad	fecha_importacion
-0.8	62.0	Andalucía	2026-01-08 22:12:39.782055
-1,7	66.0	Andalucía	2026-01-08 22:12:39.782055
	82.0	Andalucía	2026-01-08 22:12:39.782055

- 3. Carga y unificación (PostgreSQL).** Como paso final, mediante la función *Salida Tabla* de Pentaho se consolidó toda la información en una base de datos PostgreSQL. Previamente, el esquema de la base de datos se diseñó con las librerías SQLAlchemy y psycopg2 en Python.

El resultado es una tabla unificada de más de 400 registros (unos 444), actualizada en tiempo real y libre de errores estructurales. Funciona como histórico: la información ya existente no se borra, sino que se conserva, lo que permite consultar los datos que se deseen y cruzar las variables meteorológicas con el estado de los embalses y los caudales descritos en los apartados anteriores.

4.2 Clasificación de librerías especializadas

4.2.1 Adquisición de datos y conectividad web

- **Requests y urllib3:** gestión de las peticiones HTTP; permiten consumir las APIs JSON de las confederaciones hidrográficas del Ebro, Tajo y Guadiana.
- **BeautifulSoup (bs4):** extracción selectiva de datos de los HTML estáticos.
- **Selenium (WebDriver):** utilizada en los HTML dinámicos, simulando los clics en el navegador, ya que ciertos organismos renuevan el token o requieren una acción del usuario para devolver la respuesta.

4.2.2 Procesamiento y normalización alfanumérica

- **Pandas:** herramienta central para crear DataFrames, limpiar datos, filtrar registros y unificar la información.
- **RapidFuzz:** comparación de cadenas de texto, que permite vincular nombres de estaciones con ligeras variaciones ortográficas entre distintas fuentes.
- **unicodedata:** normalización de caracteres, eliminando tildes y símbolos especiales para estandarizar la búsqueda de información.

- **re (expresiones regulares):** búsqueda y extracción de patrones específicos dentro del código fuente de los portales web capturados.

4.2.3 Gestión y geoprocesamiento espacial

- **GeoPandas (gpd):** librería crítica que extiende las capacidades de Pandas al manejo de geometrías; permite leer archivos Shapefile y gestionar sus sistemas de coordenadas.

4.2.4 Persistencia y gestión de bases de datos

- **psycopg2:** adaptador de PostgreSQL que permite ejecutar sentencias SQL y gestionar el servidor PostGIS.
- **SQLAlchemy:** facilita la carga directa de datos desde Python a las tablas de la base de datos de manera eficiente.

4.2.5 Utilidades de sistema y formatos de intercambio

- **os y pathlib:** gestión de rutas de archivos en el sistema operativo, garantizando la portabilidad del código entre entornos de trabajo.
- **csv y json:** lectura y escritura de los archivos de intercambio intermedios generados tras la captura inicial.
- **datetime y time:** registro temporal de las capturas y gestión de los retardos necesarios para evitar el bloqueo por parte de los servidores externos durante el *scraping*.

4.3 Selección y justificación del sistema

4.3.1 Python: automatización y extracción de datos

La selección de Python como motor central se debe a su versatilidad para gestionar flujos de datos heterogéneos gracias a sus múltiples librerías. Este lenguaje permite automatizar la captura de información hidrológica y meteorológica en tiempo real.

4.3.2 PDI: normalización de flujos

Pentaho Data Integration (PDI) desempeña el papel de motor ETL intermedio para el tratamiento específico de la información de la red fluvial y de la temperatura. Su implementación responde a la necesidad de estandarizar datos que provienen de sistemas muy dispares.

- **Filtrado y unificación:** los datos de los ríos y las temperaturas capturados por Python pasan por una serie de pasos de transformación en PDI, donde se filtran los registros duplicados y se normaliza la nomenclatura.
- **Preparación para la base de datos:** PDI garantiza que los campos de fecha, hora y valores numéricos (caudales y niveles) tengan el formato exacto que exige el esquema de PostGIS, evitando fallos en la integración tras la inserción masiva de datos.

4.3.3 FME: geoprocesamiento y geocodificación avanzada

FME se ha integrado en la metodología como herramienta especializada en el cálculo, la transformación y la validación de geometrías complejas. Su uso es fundamental para asegurar que los datos alfanuméricos extraídos tengan una representación espacial precisa.

- **Geocodificación mediante API:** se utiliza la Geocoding API de Google desde FME para dar geometría a las estaciones de cálculo de caudal de los ríos mediante el archivo geocodingAPI.fmw. Los organismos no

publican la posición de estas estaciones por motivos de seguridad, por lo que se les asigna una localización aproximada mediante un filtro en la petición a la API.

- **Validación de topología y formato:** FME actúa como filtro de calidad antes de la carga en la base de datos, verificando que los archivos vectoriales (Shapefile) no contengan errores geométricos y que el sistema de referencia de coordenadas (CRS) sea coherente en todas las capas.
- **Cálculos geoespaciales:** se utilizan las herramientas de FME para operar con datos ráster, vectoriales y con la combinación de ambos.

Las APIs utilizadas son las siguientes:

1. **API Earth Search (STAC):** gestionada por Element 84 y basada principalmente en Sentinel-2, con los datos alojados en AWS (Amazon Web Services). Permite obtener imágenes de satélite de las zonas necesarias.
2. **Geocoding API de Google:** asigna coordenadas geográficas (latitud y longitud) a las estaciones a partir de su nombre o código identificador.
3. **PVPC (Precio Voluntario para el Pequeño Consumidor):** proporciona el precio del MWh en tiempo real.

4.3.4 PostGIS: repositorio de los datos geoespaciales

Para centralizar la información extraída de las webs y las APIs se ha creado una base de datos en PostgreSQL con la extensión PostGIS. Esta opción resulta especialmente útil para trabajar con datos espaciales, ya que permite mantener los datos alfanuméricos (como los caudales o el precio de la luz) unidos directamente a su geometría (la ubicación de los embalses o los ríos) en una misma tabla.

En el proyecto, PostGIS sirve principalmente para tres cosas:

- **Organizar los datos en un único lugar:** a través de los scripts de Python y los procesos de PDI, la información se guarda en la base de datos espacial (BDE).
- **Hacer consultas SQL espaciales:** permite relacionar fácilmente datos de diferentes fuentes.
- **Conexión directa con QGIS:** la BDE se puede conectar directamente a QGIS, de modo que cualquier cambio o actualización se refleja automáticamente en el mapa, sin tener que exportar un Shapefile cada vez que entran datos nuevos.

5. Implementación de los modelos de procesamiento y automatización

5.1 Normalización y filtrado de datos mediante PDI (Pentaho)

5.1.1 Tratamiento de los datos fluviales

Los datos fluviales se encuentran recogidos en una única carpeta, en distintos formatos: en CSV, las cuencas del Cantábrico, Duero, Guadalquivir, Júcar, Miño-Sil y Segura; en JSON, las del Ebro, Guadiana y Tajo. Los elementos utilizados para la normalización de la información son los siguientes:

- **JSON/CSV input:** leer los datos y organizarlos por columna y tipo de dato correspondiente.
- **Replace in string:** reemplazar valores dentro de una cadena de texto.
- **Selecciona/Renombrar valores:** dotar a todos los elementos comunes de un nombre normalizado y de un tipo de dato común.
- **Añadir constantes:** dotar a cada cuenca de una columna con su respectivo nombre.

- **Filtrar filas:** evitar valores nulos en el identificador, ya que el id es obligatorio y su ausencia provocaría un error en el código Python.
- **Valor JavaScript modificado:** muy útil porque muchas cuencas unen el id y el nombre en una sola columna, lo que permite separarlos cómodamente.

La Figura 2 muestra el flujo obtenido de manera individual para cada cuenca.




Figura 2. Flujo de la transformación de datos fluviales en PDI.

Esta transformación se incluye en un trabajo (*job*) para poder actualizar correctamente la información nueva (Figura 3).




Figura 3. Flujo del trabajo (*job*) en PDI.

5.1.2 Tratamiento de los datos meteorológicos (histórico)

La información meteorológica se ha procesado a partir de 16 archivos CSV independientes (uno por cada comunidad autónoma de la península). Para garantizar la interoperabilidad de estos datos «sucios» y heterogéneos se han empleado los siguientes elementos de normalización:

- **Scripts de Python (Pandas):** pieza clave para la limpieza profunda de los CSV. Se han utilizado para eliminar encabezados con metadatos irrelevantes, corregir el «texto invisible» y reordenar estructuras internas que Pentaho no podía interpretar de forma nativa.

- **Limpieza selectiva de nulos (Python):** script específico que elimina las filas con el 100 % de sus valores nulos, conservando las que contienen al menos un dato real para proteger la integridad de la serie histórica.
- **CSV input:** ingesta de los datos una vez preprocesados por Python, definiendo los tipos de datos (*string*, *numeric*) y los delimitadores correctos.
- **Añadir constantes:** crea una columna nueva al final de cada flujo que identifica la comunidad autónoma de origen, lo que permite la trazabilidad del dato tras la unificación.
- **Selecciona/Renombrar valores:** homogeneiza la nomenclatura de todas las variables (temperatura, direccion_viento, racha, etc.), asegurando que las columnas de las 16 fuentes tengan el mismo nombre y formato antes de la carga.
- **Salida tabla (PostgreSQL):** función final para cargar los datos normalizados en el repositorio central, estableciendo la conexión directa entre el flujo de Pentaho y las tablas creadas en la base de datos.

La Figura 4 muestra el flujo completo y la Tabla 15 el resultado almacenado.




Figura 4. Flujo de la transformación de meteorología (histórico) en PDI.

Tabla 15. Resultado de la tabla meteorológica (histórico), dividida en dos bloques de columnas: (a) columnas 1 a 7; (b) columnas 8 a 14.

Id	Estación	Provincia	Temperatura (°C)	Velocidad del viento (km/h)	Dirección del viento	Racha (km/h)
6012	Abla	Almería	10.6	0	Calma	8
6013	Adra	Almería	17.1	9	Norte	20
6014	Aguilar de la Frontera	Córdoba	12.1	2	Este	13

Id	Dirección de racha	Precipitación (mm)	Presión (hPa)	Tendencia (hPa)	Humedad (%)	comunidad	fecha_importacion
6012	Nordeste	0.0	909.6	-0.8	62.0	Andalucía	2026-01-08 22:12:39.782055
6013	Norte	0.0	1008.0	-1,7	66.0	Andalucía	2026-01-08 22:12:39.782055
6014	Sudeste	0.0			82.0	Andalucía	2026-01-08 22:12:39.782055

5.1.3 Tratamiento de los datos meteorológicos (actualizado con localización)

En este apartado se ha realizado una ampliación con FME para obtener las coordenadas aproximadas de las estaciones, añadiendo una columna adicional de geometría (geom) en la que se registran. A diferencia del paso anterior, aquí no se trata de un histórico que almacene información en cada actualización: cuando se cargan datos nuevos, los anteriores se sobrescriben, de modo que solo se muestran los de interés. La Figura 5 muestra el flujo y la Tabla 16 el resultado.


**Figura 5.** Flujo de la transformación de meteorología (actualizado con localización).

Tabla 16. Resultado de la tabla meteorológica (actualizada con localización), dividida en dos bloques de columnas: (a) columnas 1 a 7; (b) columnas 8 a 15.

id	Estación	Provincia	Temperatura (°C)	Velocidad del viento (km/h)	Dirección del viento	Racha (km/h)
6012	Abla	Almería	10.6	0	Calma	8
6013	Adra	Almería	17.1	9	Norte	20
6014	Aguilar de la Frontera	Córdoba	12.1	2	Este	13

id	Dirección de racha	Precipitación (mm)	Presión (hPa)	Tendencia (hPa)	Humedad (%)	comunidad	fecha_importacion	geom
6012	Nordeste	0.0	909.6	-0.8	62.0	Andalucía	2026-01-08 22:12:39.782055	
6013	Norte	0.0	1008.0	-1,7	66.0	Andalucía	2026-01-08 22:12:39.782055	
6014	Sudeste	0.0			82.0	Andalucía	2026-01-08 22:12:39.782055	

5.1.4 Tratamiento de los datos de energía solar térmica

La información relativa a la monitorización solar térmica se obtiene mediante la integración de la API de ESIOS y de datos meteorológicos locales. Para la normalización y el control de alertas de esta información se han empleado los siguientes elementos de PDI:

- **Entrada Tabla:** extrae los registros procesados desde la base de datos PostgreSQL, asegurando que la información sea la más reciente tras la ejecución del script de automatización.
- **Filtrar filas:** elemento crítico para la lógica de negocio; segmenta las provincias donde la pérdida económica (`dinero_perdido_eur`) supera el umbral establecido de 1000 €. Esto permite identificar ineficiencias críticas por exceso de temperatura.
- **Mail (correo):** automatiza las notificaciones. Este componente envía una alerta inmediata a los responsables cuando el filtro detecta una pérdida de eficiencia fuera de los parámetros normales.
- **Shell (ejecución de script):** integrado en el flujo de trabajo (*job*) para lanzar el motor de Python encargado de la extracción, el cálculo de pérdidas mediante variables térmicas y la inserción inicial en la base de datos.

La Figura 6 muestra el flujo obtenido para la gestión de alertas solares.




Figura 6. Flujo de transformación para la gestión de alertas solares en PDI.

Esta transformación se incluye dentro de un trabajo (*job*) maestro (Figura 7), que garantiza que la secuencia de ejecución sea siempre la misma: primero la actualización de datos mediante el script de procesamiento y, después, la verificación y el envío de las alertas de eficiencia.




Figura 7. Trabajo (*job*) maestro de alertas solares en PDI.

Tabla 17. Tabla resultante de la energía solar térmica, dividida en dos bloques de columnas: (a) columnas 1 a 5; (b) columnas 6 a 9.

id	fecha_hora	provincia	temperatura_c	generacion_estimada_wc
21	2026-01-15 18:54:29.806744	SEVILLA	40.00	16.98
22	2026-01-15 18:54:29.806744	BADAJOS	40.00	13.58
23	2026-01-15 18:54:29.806744	MADRID	40.00	5.66
24	2026-01-15 18:54:29.806744	VALENCIA	40.00	9.06
25	2026-01-15 18:54:29.806744	MURCIA	40.00	11.32

id	precio_luz_euro_mwh	perdida_eficiencia_pct	perdida_eficiencia_mw	dinero_perdido_eur
21	166.85	6.00	1.02	169.99
22	166.85	6.00	0.82	135.99
23	166.85	6.00	0.34	56.66
24	166.85	6.00	0.54	90.66
25	166.85	6.00	0.68	113.32

5.2 Procesamiento integral de datos espaciales en FME

5.2.1 Geocodificación y automatización del posicionamiento espacial aproximado

Por motivos de seguridad y privacidad, las estaciones que suministran la información sobre el caudal de los ríos en España carecen de una georreferenciación pública explícita. Para resolver esta limitación se ha desarrollado un flujo de trabajo en FME (geocodingAPI.fmw, Figura 8) que asigna coordenadas aproximadas a partir de la información descriptiva disponible.




Figura 8. Flujo de geocodificación en FME (geocodingAPI.fmw).

El proceso se divide en siete etapas para garantizar la integridad y la correcta ubicación de los activos hídricos:

- 1. Reader (caudales_saih):** se cargan los datos necesarios de la tabla de caudales.

2. **Depuración de datos (DuplicateFilter):** para evitar peticiones HTTP repetidas a servicios externos y redundancias en la base de datos final, se filtran los registros y se procesan solo las estaciones únicas.
3. **Contextualización de la búsqueda (StringConcatenator):** para mejorar la petición a la API, este transformador concatena el nombre de la estación con la cadena «ríos, España», evitando confusiones con lugares de nombre similar en otros países.
4. **Geocodificación (Geocoder):** consulta a la API de Google Geocoding. El motor interpreta la cadena de texto y devuelve las coordenadas geográficas (latitud y longitud) más probables de la ubicación de la estación.
5. **Generación de entidades de punto (VertexCreator):** toma las coordenadas obtenidas de la API y genera una geometría de tipo punto para cada registro, convirtiendo el dato tabular en un objeto espacial.
6. **Normalización cartográfica (Reprojector):** las coordenadas devueltas por Google están originalmente en WGS84. Para asegurar la coherencia con la cartografía oficial de España utilizada en el proyecto, se reproyectan al sistema EPSG:25830 (ETRS89 / UTM zona 30N).
7. **Writer:** se incorpora la nueva información a la base de datos espacial (BDE).

5.2.2 Obtención de imágenes satelitales y procesamiento geométrico de embalses

Este proceso automatiza la vinculación entre los objetos vectoriales (polígonos de embalses) y los datos de observación de la Tierra (imágenes satelitales). En lugar de realizar una búsqueda manual, se ha desarrollado un flujo en FME (satelite.fmw, Figura 9) que identifica y selecciona de forma masiva y eficiente las mejores imágenes de Sentinel-2.




Figura 9. Flujo de obtención de imágenes satelitales en FME (satelite.fmw).

El flujo se compone de los siguientes pasos:

1. **Reader** (public_embalses_geom): se parte de la geometría vectorial (polígonos) que delimita cada embalse.
2. **Reprojector**: asegura que toda la información tenga la misma proyección.
3. **BoundsExtractor y GeometryExtractor**: calculan la extensión máxima (*bounding box*) y extraen la geometría para definir el área exacta donde el satélite debe buscar imágenes.
4. **JSONTemplater**: construye la solicitud formal de datos.
5. **HTTPCaller**: actúa como puente web, conectándose con el servidor satelital para solicitar las capturas disponibles.
6. **JSONFragmenter y JSONFlattener**: descomponen la respuesta del servidor (un JSON complejo) en una tabla de atributos sencilla con las fechas de captura y los enlaces de descarga.
7. **Sorter y Sampler**: filtran los resultados para seleccionar únicamente la imagen más reciente o de mejor calidad (menor nubosidad), descartando el resto de la información.

- La presencia de nubes suele reducir la calidad de las imágenes satelitales, por lo que este flujo facilita la comparación de imágenes de una misma zona y permite seleccionar automáticamente la que tiene menos nubes, asegurando la visibilidad de la superficie del embalse.

El objetivo de este flujo (energía.fmw, Figura 10) es calcular la energía y el precio que se obtendrían al vaciar un embalse a su capacidad máxima y al vaciar el volumen almacenado en tiempo real.



Para esta transformación se descarga el modelo digital del terreno (MDT) de España con paso de malla de 200 m, del que se obtiene la altura (Z) del relieve. Para calcular la altura del embalse se transforma cada polígono en un punto contenido en él (se supone que todo el embalse se encuentra a la misma cota). Para calcular la altura del generador se crea un *buffer* alrededor de dicho punto y se toma como cota la altura mínima, ya que a mayor diferencia de altura se genera más energía. La diferencia de altura aplicada en cada caso es:

Siendo:

$Z(E)$: altura del embalse (m).

La energía de cada embalse se calcula mediante la siguiente fórmula:

Siendo:

g: aceleración de la gravedad, $9,81 \text{ m/s}^2$.

$V(E)$: volumen del embalse en m^3 . Los datos originales están en hm^3 , por lo que se aplica $1\text{ }hm^3 = 10^6\text{ }m^3$.

$\Delta H(E,G)$: diferencia de alturas (m).

Carlos del Valle · Enero 2025

Dado que $1 \text{ Wh} = 3600 \text{ J}$, se cumple que $1 \text{ MWh} = 3,6 \cdot 10^9 \text{ J}$. Reescribiendo la fórmula:

$$E(\text{MWh}) = \frac{\rho \cdot g \cdot V(E) \cdot \Delta H(E, G) \cdot \eta}{3,6 \cdot 10^9}$$

A partir de esta fórmula se calcula la energía que produce el embalse con su volumen actual. Además, se calcula el máximo que podría generar estando totalmente lleno, sustituyendo $V(E)$ por la capacidad del embalse.

Estos resultados corresponden al vaciado completo del embalse. En la práctica habría que multiplicarlos por un factor de vaciado $\mu(E)$, que representa el porcentaje de agua que se desea utilizar para generar energía.

6. Fuentes de datos y APIs

La Tabla 18 resume las fuentes externas empleadas en el proyecto.

Tabla 18. Fuentes de datos y APIs utilizadas.

Fuente	Uso en el proyecto	Enlace
embalses.net	Estado, capacidad y variación de los embalses	https://www.embalses.net
MITECO – Sistemas SAIH	Caudales y niveles por demarcación hidrográfica	miteco.gob.es/.../saih/
AEMET – Observación	Datos meteorológicos horarios (CSV)	aemet.es/.../observacion/
AEMET OpenData	Temperatura en capitales de provincia	opendata.aemet.es
Red Eléctrica – ESIOS	Precio PVPC (indicador 1001) y generación fotovoltaica (indicador 1739)	api.esios.ree.es
Earth Search (Element 84, STAC)	Imágenes Sentinel-2 de los embalses	earth-search.aws.element84.com/v1
Google Geocoding API	Geocodificación aproximada de las estaciones de caudal	developers.google.com/maps/.../geocoding